

Sistema preditivo hospitalar

Classificação do nível de obesidade

Aplicação Streamlit · diagnóstico · painel analítico

Olá, eu sou Delmir Bartolomeu Sobrinho. Este é o sistema preditivo hospitalar de classificação da obesidade, desenvolvido no Tech Challenge da fase 4 da POSTECH FIAP.

O problema no hospital

Doença crônica

A obesidade envolve genética, ambiente e comportamento.

Triagem desigual

O primeiro olhar de risco muda de profissional para profissional.

Apoio, não substituto

O sistema padroniza a classificação em sete níveis e devolve a conduta à equipe.

Atuo como cientista de dados de um hospital. A obesidade é crônica e multifatorial. A triagem hoje é lenta e o olhar de risco varia. O objetivo é padronizar o primeiro filtro, sem substituir o médico.

Entregas da disciplina

- ✓ Pipeline de machine learning, com preparação dos dados e treino.
- ✓ Modelo com assertividade acima de 75% no teste — na prática, 98,35%.
- ✓ Aplicação preditiva no Streamlit, em produção na nuvem.
- ✓ Painel analítico com insights para a equipe médica.
- ✓ Repositório no GitHub com o código e o modelo.
- ✓ Este vídeo: sistema e dashboard em visão de negócio.

As entregas da disciplina estão neste aplicativo: pipeline de machine learning, modelo acima de setenta e cinco por cento, sistema preditivo no Streamlit, painel analítico, repositório no GitHub e este vídeo em visão de negócio.

O aplicativo — diagnóstico preditivo

Navegação clínica

Selecione a visão:

Diagnóstico preditivo

Painel analítico e insights

Tech Challenge Fase 4 — POSTECH FIAP

Ferramenta de apoio à triagem hospitalar.

Inferência local (modelo serializado)

Sistema de Apoio à Decisão Médica: Predição de Obesidade

Preencha os dados clínicos e comportamentais do paciente para obter o nível estimado de obesidade. O resultado é um apoio à triagem e não substitui avaliação médica presencial.

1. Dados biométricos

Gênero

Feminino

Idade (anos)

25

Altura (m)

1.70

Peso (kg)

70.00

2. Hábitos alimentares

Histórico familiar de excesso de peso?

Sim

Consome alimentos muito calóricos com frequência (FAVC)?

Sim

Frequência de consumo de vegetais (1 = raro, 3 = sempre)

2

Número de refeições principais por dia

3

Lanches entre refeições (CAEC)

Às vezes

Monitora calorias diárias (SCC)?

Não

3. Estilo de vida e rotina

Fumante?

Não

Consumo de água (1 = <1 L, 2 = 1-2 L, 3 = >2 L)

2

Atividade física semanal (0 = nenhuma, 3 = 5x+)

1

Tempo em telas por dia (0 = 0-2 h, 2 = >5 h)

1

Consumo de álcool (CALC)

Às vezes

Meio de transporte habitual


Transporte público

Executar diagnóstico clínico

IMC pré-calculado com os dados atuais: 24.22 kg/m² (Peso normal pela referência da OMS).

O aplicativo tem duas visões. Nesta, o profissional preenche dados biométricos, hábitos alimentares e estilo de vida. O IMC já aparece como referência clínica. Em seguida, executa o diagnóstico.

Exemplo de diagnóstico



Paciente de quarenta e dois anos, um metro e setenta, cento e vinte quilos. O sistema prediz obesidade tipo dois, com IMC de quarenta e um e meio. A OMS, só pelo IMC, apontaria tipo três. O gráfico mostra a confiança em cada nível.

Como a equipe lê o resultado

Classe predita

O nível estimado em sete classes, em português.

IMC e faixa OMS

Métrica clínica ao lado da predição, para cruzar as duas leituras.

Confiança


Probabilidade em cada nível. Útil quando o caso está na fronteira.

Limite

Apoio à triagem. Conduta — dieta, exame, encaminhamento — é da equipe.

O médico lê três coisas: a classe predita, o IMC com a faixa da OMS e a probabilidade. Quando as duas leituras divergem, vale revisar o contexto comportamental. Continua sendo apoio à triagem.

Painel analítico — visão da gestão



A segunda visão é o painel da gestão. São dois mil cento e onze pacientes. Oitenta e dois por cento com histórico familiar, cinquenta e nove por cento sedentários, oitenta e oito por cento com consumo calórico frequente. Diagnóstico e painel no mesmo endereço.

Hábitos que mudam a conduta



Três achados. Histórico familiar se concentra nos níveis graves. Atividade física cai quando a obesidade sobe. Alimento calórico é o hábito dominante. O IMC separa os níveis; os hábitos dizem por onde intervir.

Pipeline de machine learning

1

Dados

Biometria, família, alimentação e rotina.

2

IMC

Peso sobre altura ao quadrado, como apoio clínico.

3

Preparação

Números na mesma escala; categorias transformadas.

4

Modelos

Random Forest e Gradient Boosting, no mesmo fluxo.

A pipeline padroniza números, transforma categorias e calcula o IMC como métrica de apoio. Comparamos Random Forest e Gradient Boosting. O mesmo pré-processamento segue até a aplicação.

Assertividade do modelo

Mínimo exigido

75%

Campeão no teste · Gradient Boosting

98,35%

Comparação

Gradient Boosting 98,35% no teste

Random Forest 97,87% no teste

Validação cruzada 97,5% $\pm$ 0,8%

Os dois passam do critério.

O campeão é o modelo do aplicativo.

O critério da disciplina era setenta e cinco por cento. O Gradient Boosting chegou a noventa e oito vírgula trinta e cinco no teste. O Random Forest, noventa e sete vírgula oitenta e sete. O campeão foi serializado e é este que o aplicativo usa.

Produção e extras

Streamlit Cloud

avaliapeso.streamlit.app

Deploy oficial: diagnóstico e painel no mesmo link.

GitHub

[fase4-postech / main](#)

Código, pipeline, modelo e documentação.

Extra MLOps

FastAPI + Docker

API de inferência e containers unindo API e tela.

O deploy oficial é o Streamlit Cloud: [avaliapeso](#) ponto [streamlit](#) ponto [app](#). O código está no GitHub, branch main. Como extra de produção, o mesmo modelo sobe em API FastAPI e em Docker, junto com a tela.

Impacto e encerramento

- Primeira triagem mais curta e padronizada em sete níveis.
- Painel para campanha de prevenção: família, exercício e alimentação.
- Próximo passo no hospital: validar na unidade e, se fizer sentido, ligar a API ao prontuário.

Na prática, a primeira triagem fica mais curta e padronizada. O painel alimenta prevenção. Obrigado. Fico à disposição da banca.